

UNIVERSIDADE FEDERAL DO ESPÍRITO SANTO
DEPARTAMENTO DE ESTATÍSTICA
ANÁLISE DE SOBREVIVÊNCIA

**Abordagens Paramétricas e Não-Paramétricas em Análise de
Sobrevivência**

Aluna: Vitória Nascimento de Jesus Sesana

Professora: Agatha Sacramento Rodrigues

Vitória - ES
2024

Sumário

1	Introdução	2
2	Metodologia	2
2.1	Função de Sobrevivência	2
2.2	Estimador Kaplan-Meier	2
2.3	Teste de Log-Rank	2
2.4	Modelos probabilísticos	2
3	Cenário 1: Doença de Hodkings	2
3.1	Kaplan-Meier por Gêneros	3
3.2	Kaplan-Meier por Faixas Etárias	4
3.3	Kaplan-Meier por Tipos de Linfomas	5
3.4	Kaplan-Meier por Estágios da Doença	6
4	Cenário 2: Resistência de Isolentes Térmicos	8
4.1	Modelos Paramétricos	8
4.1.1	Tempo Mediano	10
4.1.2	Tempo Médio	10
4.1.3	Tempo de ruptura	10
5	Referências	11
6	Apêndices	11
6.1	Códigos utilizados no Cenário 1	11
6.2	Códigos utilizados no Cenário 2	14

1 Introdução

A necessidade de analisar o tempo até a ocorrência de um evento é demandado em diversas áreas do conhecimento. Um exemplo, aplicado na área da saúde, seria o interesse em verificar o tempo até o óbito de pacientes após receberem um tratamento específico para uma doença grave, como câncer.

No entanto, é comum no processo da coleta dos dados haja unidades com imprecisão ou a não observação do tempo exato da ocorrência do evento. Diz-se que estas unidades são unidades censuradas ou que sofreram censura.

Intuitivamente, muitos optam por eliminar as observações que contém censura, mesmo com algum tipo de informação já coletada. Desse modo, a perda de informação impactaria nas conclusões finais relacionadas ao estudo. Diante disso, a Análise de Sobrevivência busca solucionar esse problema com um conjunto de técnicas que permitem incluir a censura em seus cálculos.

A análise de sobrevivência pode ser abordada por duas formas: paramétrica e não-paramétrica. Os métodos paramétricos, ao contrário dos métodos não-paramétricos, pressupõem que os dados são provenientes de um tipo de distribuição de probabilidade. Cada metodologia possui suas próprias técnicas a fim de concluir informações a respeito do problema em estudo.

O objetivo desse relatório é aplicar tais abordagens em dois cenários distintos. O primeiro cenário é relacionado ao tempo de vida de pacientes diagnosticados com a doença de Hodgkins, utilizando métodos não-paramétricos. Em contraponto, o segundo cenário possui como foco o tempo de resistência de isolantes térmicos até a sua ruptura, quando submetidos a altas tensões. Neste caso, será utilizado métodos paramétricos.

2 Metodologia

2.1 Função de Sobrevivência

Seja T , chamada como tempo de falha, uma variável aleatória que mede o tempo até a ocorrência de um evento, a função sobrevivência descreve a probabilidade da observação não falhar após o tempo t . O interesse principal é estimar a função de sobrevivência, a partir dela consegue-se obter outras medidas úteis para a interpretação do contexto do problema em estudo.

2.2 Estimador Kaplan-Meier

O estimador de Kaplan-Meier, ou estimador limite-produto, é um dos métodos não-paramétricos utilizado para estimar a função de sobrevivência $S(t)$. Uma de suas vantagens é a não necessidade de supor distribuição probabilística aos dados, ao mesmo tempo que considera as censuras em seus cálculos.

2.3 Teste de Log-Rank

É um teste não paramétrico utilizado na comparação de curvas de sobrevida entre dois ou mais grupos.

2.4 Modelos probabilísticos

Uma alternativa para estimar a função de sobrevivência é supor que a variável tempo de falha seja descrita como uma distribuição de probabilidade. A partir disso, utiliza-se métodos inferenciais, como o estimador de máxima verossimilhança, para estimar parâmetros da distribuição de probabilidade e posteriormente estimar a função de sobrevivência. O método da máxima verossimilhança é o mais adequado, pois ele considera censura em suas estimativas.

3 Cenário 1: Doença de Hodgkins

Segundo o Ministério da Saúde, o linfoma ou doença de Hodgkins é um câncer que afeta o sistema linfático, conjunto de tecidos e órgãos responsáveis pela imunidade e vasos que conduzem essas células através do corpo.

Em 1997, Bartolucci e Fraser apresentaram uma base de dados de 60 pessoas que receberam tratamento padrão para a doença com as seguintes variáveis:

- **id**: Identificação do paciente;

- **survivaltime**: Tempo de vida, em meses;
- **dead**: Indicador de óbito (0 - não; 1 - sim);
- **age**: Idade em anos;
- **sex**: Gênero (0 - feminino; 1- masculino);
- **stage**: Estágio da doença (0 - inicial; 1 - avançado);
- **hist**: Tipo de linfoma (1 - esclerose nodular; 2 - misto celular; 3 - depleção de linfócitos).

Neste cenário, a variável de interesse é o tempo de vida, em meses, dos pacientes com a doença de Hodkings, *survivaltime*, e a variável indicadora da taxa de falha é *dead*, as demais são características adicionais dos pacientes, denominadas covariáveis.

Com o propósito de analisar o comportamento do tempo de sobrevida dos pacientes entre grupos, será calculado as estimativas pelo método de Kaplan-Meier nos níveis das covariáveis *sex*, *age*, *hist* e *stage*. Não somente, também será aplicado o teste de Log-Rank para testar a proporcionalidade entre os níveis de cada covariável.

Vale ressaltar que a covariável *age* foi categorizada para se adequar a solução proposta.

- **age**: Idade intervalar ("53 anos ou mais"; "38 anos até menos 53 anos"; "25 anos até menos 38 anos"; "menos de 25 anos").

Tabela 1: Medidas descritivas sobre o tempo de vida, em meses, até o óbito de pacientes com doença de Hodkings.

	Mínimo	Média	Mediana	Desvio Padrão	Máximo
Tempo	0.37	27.35	29.12	17.46	66.13

3.1 Kaplan-Meier por Gêneros

Na Tabela 2 é observado a relação entre quantidade de eventos que apresentaram a taxa de falha, óbito pela doença de Hodkings, e o gênero dos pacientes. Percebe-se que, entre os gêneros, há mais pacientes masculinos (70%) do que femininos (30%).

Tabela 2: Valores cruzados de quantidade e proporções entre a ocorrência de óbito e gênero.

	Obito não observado	Obito observado	Total
Feminino	9 (15.0%)	9 (15.0%)	18 (30.0%)
Masculino	21 (35.0%)	21 (35.0%)	42 (70.0%)
Total	30 (50.0%)	30 (50.0%)	60 (100.0%)

A Figura 1 apresenta as funções de sobrevivência estimada por gênero feminino e masculino. É observável que as funções de sobrevida se cruzam em diversos pontos ao longo do tempo.




Figura 1: Estimativas por gênero da função de sobrevivência de pacientes com a doença de Hodkings utilizando Kaplan-Meier.

Entretanto, os resultados apresentados na Tabela 3 concluíram que não foram encontradas evidências entre diferenças nas funções de sobrevivência estimadas.

Tabela 3: Resultados teste de Log-Rank para comparações entre gêneros

Estatística de teste	Valor p
0.0303	0.8618

3.2 Kaplan-Meier por Faixas Etárias

A Tabela ?? apresenta iformações por nível de faixa etária. Percebe-se que a proporção entre os níveis não apresentam variação.

??

Tabela 4: Valores cruzados de quantidade e proporções entre a ocorrência de óbito e faixa etária.

	Obito não observado	Obito observado	Total
53 anos ou mais	7 (11.7%)	9 (15.0%)	16 (26.7%)
38 anos até menos 53 anos	9 (15.0%)	5 (8.3%)	14 (23.3%)
25 anos até menos 38 anos	4 (6.7%)	11 (18.3%)	15 (25.0%)
menos de 25 anos	10 (16.7%)	5 (8.3%)	15 (25.0%)
Total	30 (50.0%)	30 (50.0%)	60 (100.0%)

A Figura 2 apresenta as estimativas da função de sobrevida por Kaplan-Meier por nível de faixa etária. Percebe-se que para os pacientes de 25 até 38 anos apresentam decaimento da curva mais acelerado que dos demais níveis, indicando que pacientes nessa faixa etária tendem a apresentar a taxa de falha em menor tempo.

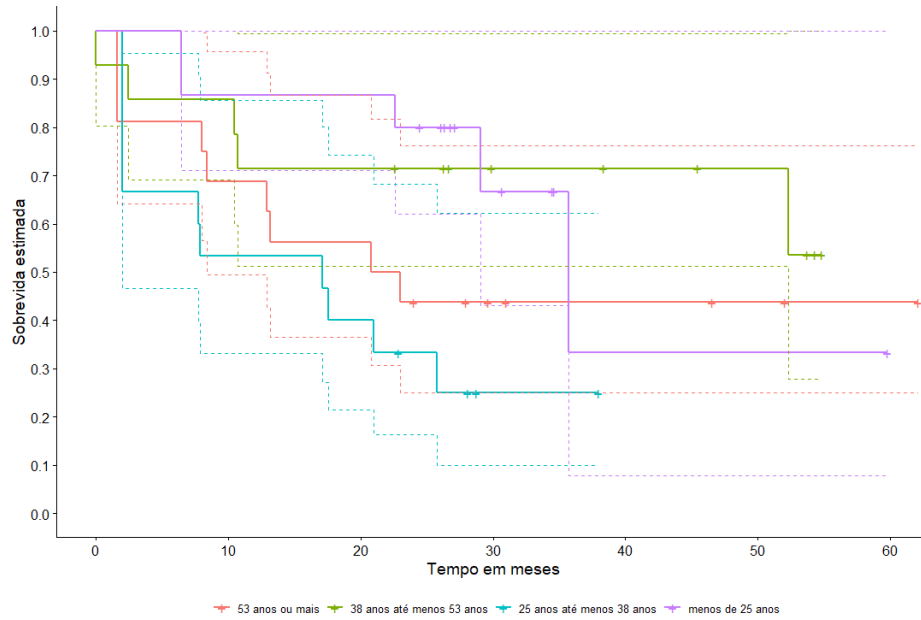


Figura 2: Estimativas por faixa etária da função de sobrevivência de pacientes com a doença de Hodkings utilizando Kaplan-Meier.

Como mostra a Tabela 6, os resultados indicam que há diferenças significativas entre os níveis da faixa etária.

Tabela 5: Resultados teste de Log-Rank para comparações entre faixas etárias.

Estatística de teste	Valor p
9.2433	0.0262

3.3 Kaplan-Meier por Tipos de Linfomas

Percebe-se, na Tabela 6, que há poucos pacientes com o fepleção de linfócitos (11.7%) e mais pacientes com esclerose nodular (53,3%).

Tabela 6: Valores cruzados de quantidade e proporções entre a ocorrência de óbito e tipo de linfoma.

	Óbito não observado	Óbito observado	Total
Esclerose nodular	18 (30.0%)	14 (23.3%)	32 (53.3%)
Fepleção de linfócitos	1 (1.7%)	6 (10.0%)	7 (11.7%)
Misto celular	11 (18.3%)	10 (16.7%)	21 (35.0%)
Total	30 (50.0%)	30 (50.0%)	60 (100.0%)

Na Figura 3, percebe-se que o decaimento da curva de sobrevivência estimada para os indivíduos com fepleção de linfócitos é mais acelerada do que para os demais tipos de linfócitos, ou seja, indivíduos com este tipo de linfoma apresentaram o tempo de falha em menor tempo do que os demais, o que indicaria que as curvas de sobrevida são diferentes entre si.

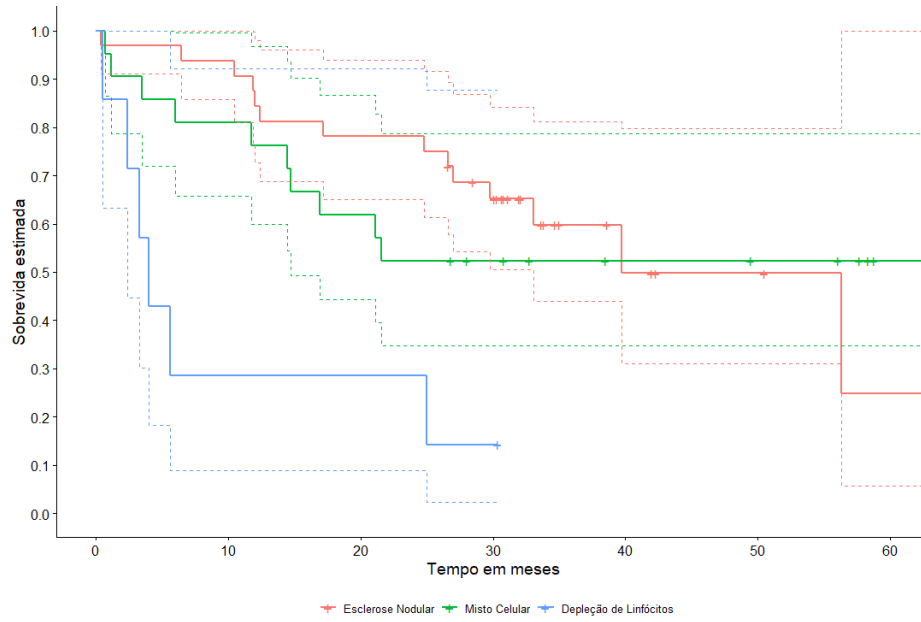


Figura 3: Estimativas por tipo de linfoma da função de sobrevivência de pacientes com a doença de Hodkings utilizando Kaplan-Meier.

A Tabela 8, assim como na Tabela 6, indica que há diferença nas curvas de sobrevida estimada entre os tipos de linfoma.

Tabela 7: Resultados teste de Log-Rank para comparações entre tipos de linfomas.

Estatística de teste	Valor p
12.7973	0.0016

3.4 Kaplan-Meier por Estágios da Doença

Observando pela perspectiva dos estágio da doença, há mais pacientes no estágio mais avançado do que (56.7%) em estágios iniciais (43.3%).

Tabela 8: Valores cruzados de quantidade e proporções entre a ocorrência de óbito e estágio da doença.

	Óbito não observado	Óbito observado	Total
Avançado	13 (21.7%)	21 (35.0%)	34 (56.7%)
Inicial	17 (28.3%)	9 (15.0%)	26 (43.3%)
Total	30 (50.0%)	30 (50.0%)	60 (100.0%)

Observando a Figura 4, verifica-se que as estimativas da função de sobrevida para pacientes com o estágio avançado da doença apresentam decaimento maior que a de pacientes em estágio inicial, indicando que as curvas de sobrevida entre os estágios sejam diferentes.




Figura 4: Estimativas por estágio da doença da função de sobrevivência de pacientes com a doença de Hodkings utilizando Kaplan-Meier.

Na Tabela 9, há evidências que indicam a diferença entre as curvas de sobrevivência estimadas entre o estágio inicial da doença e o estágio final.

Tabela 9: Resultados teste de Log-Rank para comparações entre estágios da doença.

Estatística de teste	Valor p
4.1425	0.0418

4 Cenário 2: Resistência de Isolantes Térmicos

Realizou-se um experimento para verificar o tempo de resitência de isolantes elétricos sob alta tensão. A parti disso, 25 unidades de isolantes elétricos foram submetidos a uma tensão de 35Kvolts até que 15 deles falhassem. O tempo até a ruptura dos 15 isolantes elétricos são motrados na Tabela 10.

Tabela 10: Tempo da ruptura de 15 isolantes elétricos, em minutos, submetidos a uma tensão de 35 Kvolts.

0.19	0.78	0.96	1.31	2.78	3.16	4.67	4.85
6.50	7.35	8.27	12.07	32.52	33.91	36.71	

Neste experimento, o tipo de censura apresentado é censura à direita tipo II com 15 observações que apresentassem a ruptura durante o experimento.

4.1 Modelos Paramétricos


Para realizar suposições a respeito do tempo de ruptura dos isolantes elétricos utilizados no problema, foram estimadas funções de sobrevivências nos tempos coletados para quatro modelos probabilísticos a fim de selecionar aquele que mais se adequa aos dados. As estimativas são apresentados na Tabela 11.

Tabela 11: Estimativas de sobrevivência para os tempos de ruptura de isolantes térmicos usando estimadores de Kaplan-Meier e os modelos exponencial, Weibull, log-normal e log-logística.


	Tempo	Kaplan-Meier	Exponencial	Weibull	Log-Normal	Log-Logística
1	0.19	0.93	0.98	0.96	0.99	0.98
2	0.78	0.87	0.93	0.87	0.89	0.90
3	0.96	0.80	0.91	0.85	0.86	0.87
4	1.31	0.73	0.88	0.81	0.80	0.83
5	2.78	0.67	0.77	0.68	0.63	0.66
6	3.16	0.60	0.74	0.65	0.60	0.62
7	4.67	0.53	0.64	0.56	0.49	0.51
8	4.85	0.47	0.63	0.55	0.48	0.50
9	6.50	0.40	0.54	0.47	0.40	0.41
10	7.35	0.33	0.49	0.43	0.37	0.38
11	8.27	0.27	0.45	0.40	0.34	0.34
12	12.07	0.20	0.31	0.29	0.25	0.25
13	32.52	0.13	0.04	0.06	0.09	0.09
14	33.91	0.07	0.04	0.06	0.08	0.09
15	36.71	0.00	0.03	0.05	0.07	0.08

O estimador de Kaplan-Meier também foi calculado para servir de comparação com os modelos, aquele que mais se assemelha as estimativas de Kaplan-Meier será o mais adequado.


Uma das alternativas para verifica é comparar gráficamente a função de sobrevida estimada do Kaplan-Meier com a função de sobrevida estimada pelo modelo. Diante disso, os resultados são apresentados na Figura .




(a) Modelo exponencial.



(b) Modelo Weibull.



(c) Modelo log-normal.



(d) Modelo log-logística.

Figura 5: Gráficos das sobrevivências estimadas por Kaplan-Meier *versus* as sobrevivências estimadas pelos modelos exponencial, Weibull, log-normal e log-logística

A Figura 5 indica que os modelos log-normal, Subfigura 5c, e log-logística, Subfigura 5d, apresentaram melhor desempenho em se ajustar as estimativas por Kaplan-Meier.

Para critério de desempate, a seleção do modelo será realizada com base no menor erro quadrático médio. Desse modo, observando os resultados da Tabela 12, o modelo log-normal (0.00212) é o modelo que melhor representa o comportamento da variável de interesse do problema apresentado.

Tabela 12: Erro quadrático médio dos modelos exponencial, Weibull, log-normal e log-logística em relação as estimativas de Kaplan-Meier.

	Exponencial	Weibull	Log-Normal	Log-Logística
EQM	0.01379	0.00425	0.00212	0.00251

As estimativas dos parâmetros do modelo log-normal, em escala original, e seus intervalos são mostrados na Tabela 13. Obteve-se que a média, um dos parâmetros da distribuição log-normal, é de 1.51, $IC[\mu; 95\%] = (0.78, 2.25)$, e o desvio padrão, outro parâmetro da distribuição log-normal, estimado em 1.45, $IC[\sigma; 95\%] = (1.01, 2.07)$

Tabela 13: Estimativa e intervalo de confiança da média e desvio padrão do modelo log-normal em escala original.

	Estimativa	L95%	U95%
Média	1.51	0.78	2.25
Desvio padrão	1.45	1.01	2.07

Com o modelo selecionado e seus parâmetros estimados, a função de sobrevivência estimada no tempo t é dada

por:

$$\begin{aligned} S(t) &= \phi\left(\frac{-\log(t) + \mu}{\sigma}\right) \\ \widehat{S}(t) &= \phi\left(\frac{-\log(t) + 1.51}{1.45}\right) \end{aligned} \quad (1)$$

4.1.1 Tempo Mediano

O percentil da distribuição log-normal podem ser obtidos utilizando a tabela normal padrão com base na seguinte equação:

$$t_p = \exp\{z_p\sigma + \mu\} \quad (2)$$

Para o tempo mediano, o cálculo se dar por:

$$\begin{aligned} \widehat{t}_{0.5} &= \exp\{z_{0.5}1.45 + 1.51\} \\ &= 4.54 \end{aligned} \quad (3)$$

4.1.2 Tempo Médio

A estimativa do tempo médio de vida deste tipo de isolante elétrico funcionando a 35 Kvolts para o modelo selecionado é dado por:

$$E[T] = \exp\{\mu + \sigma^2/2\} \quad (4)$$

Desse modo, o tempo de vida médio estimado é de:

$$\begin{aligned} \widehat{E}[T] &= \exp\{1.51 + (1.45)^2/2\} \\ &= 12.96 \end{aligned} \quad (5)$$

4.1.3 Tempo de ruptura

O tempo necessário para que 20% dos isolantes estarem fora de operação é a função de distribuição da log normal no tempo 20, ou seja, $F_{ln}(t) = 0.20$.

$$\begin{aligned} F_{ln}(t) &= \phi\left(\frac{\log(t) - \mu}{\sigma}\right) \\ 0.2 &= F_z\left(\frac{\log(t) - \mu}{\sigma}\right) \\ 0.2 &= P\left(Z \leq \frac{\log(t) - \mu}{\sigma}\right) \\ 0.2 &= P(Z \leq z_{0.2}) \end{aligned} \quad (6)$$

Sendo $z_{0.2} = -0.8416212$.

$$\begin{aligned} z_{(0.2)} &= \frac{\log(t) - \mu}{\sigma} \\ t &= e(z_{(0.2)}\sigma + \mu) \\ \widehat{t} &= e(-0.8416212 * 1.45 + 1.51) \\ \widehat{t} &= 1.341276 \end{aligned} \quad (7)$$

5 Referências

1. COLOSIMO, Enrico Antônio; GIOLO, Suely. Análise de sobrevivência aplicada. São Paulo: Blucher, c2006. 367p
2. Bartolucci, A. A., & Fraser, M. D. (1977). Comparative Step-Up and Composite Tests for Selecting Prognostic Indicators Associated with Survival. Biometrical Journal, 19(6), 437–448. doi:10.1002/bimj.4710190607
3. BRASIL. Ministério da Saúde. Instituto Nacional de Câncer - INCA. Linfoma de Hodgkin, 2022. Disponível em: <https://www.gov.br/inca/pt-br/assuntos/cancer/tipos/linfoma-de-hodgkin>. Acesso em: 01 mai. 2024.

6 Apêndices

6.1 Códigos utilizados no Cenário 1

```
1 # AN LISE DE SOBREVIV NCIA
2 # EXERCICIO 4 DA LISTA 2
3
4 # bibliotecas -----
5 require(survival)
6 require(survminer)
7 require(summarytools)
8 require(dplyr)
9
10 # base de dados -----
11 base <- readxl::read_xlsx("AS_lista2/Lista2_Hodgkins.xlsx") %>%
12   mutate(aux_age = case_when(
13     (age > 53) ~ "53 anos ou mais",
14     (age >= 38 & age < 53) ~ "38 anos at menos 53 anos",
15     (age >= 25 & age < 38) ~ "25 anos at menos 38 anos",
16     (age < 25) ~ "menos de 25 anos",
17   ),
18   aux_dead = case_when(
19     dead == 0 ~ "Evento n o observado",
20     dead == 1 ~ "Evento observado"
21   ),
22   aux_sex = case_when(
23     sex == 0 ~ "Feminino",
24     sex == 1 ~ "Masculino"
25   ),
26   aux_stage = case_when(
27     stage == 0 ~ "Inicial",
28     stage == 1 ~ "Avan ado"
29   ),
30   aux_hist = case_when(
31     hist == 1 ~ "Esclerose nodular",
32     hist == 2 ~ "Misto celular",
33     hist == 3 ~ "Feple o de linf citos"
34   ),
35   aux_age = factor(aux_age, labels = c("53 anos ou mais",
36                                         "38 anos at menos 53 anos",
37                                         "25 anos at menos 38 anos",
38                                         "menos de 25 anos"))
39 )
40
41 # analise descritiva -----
42 ctable(base$aux_sex, y=base$aux_dead, prop="t")
43 ctable(base$aux_age, y=base$aux_dead, prop="t")
44 ctable(base$aux_hist, y=base$aux_dead, prop="t")
45 ctable(base$aux_stage, y=base$aux_dead, prop="t")
46
47 ggplot(base) +
48   aes(x = survivaltime, y = aux_dead) +
49   geom_boxplot(fill = "#0c4c8a") +
50   labs(x = "Tempo de vida dos pacientes", y = "G nero") +
51   theme_minimal()
52
53 # descritiva survivaltime -----
54
55 min(base$survivaltime) # minimo em meses
```

```

56 min(base$survivaltime)*30 # minimo em dias
57 max(base$survivaltime) # m ximo em meses
58 max(base$survivaltime)/12 #m ximo em dias
59
60 boxplot(base$survivaltime, horizontal = TRUE)
61
62 descr(base$survivaltime, stats = c("min", "mean", "med", "sd", "max"),
63       transpose = TRUE)
64
65 # tabela observa es e censuras -----
66 Surv(time = base$survivaltime, event = base$dead)
67
68 # genero -----
69 ajuste_sexo <-
70   survfit(
71     Surv(time = survivaltime,
72          event = dead) ~ aux_sex,
73     data = base
74   )
75
76 ajuste_sexo <- survfit(Surv(time = survivaltime,
77                          event = dead) ~ sex,
78                      data = base)
79
80 #Para fazer a tabela da estimativa de KM e intervalo de confian a:
81 surv_summary(ajuste_sexo, data = lung)
82
83 # estimativas sobrevida por kaplan-meier
84 kp_sexo <- surv_summary(ajuste_sexo,
85                        data = base)
86
87 # gr fico sobrevida estimada
88 gg_sexo <- survminer::ggsurvplot(ajuste_sexo, data = base,
89                                pval = FALSE, conf.int=TRUE, conf.int.style = "ribbon",
90                                ylab = "Sobrevida estimada",
91                                xlab = "Tempo em meses",
92                                legend.title = "",
93                                legend.labs = c("Feminino", "Masculino"))
94
95 gg_sexo$plot <- gg_sexo$plot +
96   scale_y_continuous(limits = c(0, 1),
97                     breaks = seq(0, 1, by = 0.1)) +
98   scale_x_continuous(limits = c(0, max(base$survivaltime)),
99                     breaks = seq(0, max(base$survivaltime), by = 10)) +
100  theme(legend.position = "bottom")
101
102 # teste log-rank
103 test_sexo <- survdiff(Surv(time = survivaltime,
104                          event = dead) ~ sex,
105                      data = base)
106
107 # faixa etaria -----
108 ajuste_age <- survfit(
109   Surv(time = survivaltime,
110        event = dead,
111        type = "right",
112        origin = 4) ~ aux_age,
113   data = base)
114
115 # estimativas sobrevida por kaplan-meier
116 kp_age <- surv_summary(ajuste_age, data = base)
117
118 # gr fico sobrevida estimada
119 gg_age <- survminer::ggsurvplot(ajuste_age, data = base,
120                                pval = FALSE, conf.int=TRUE,
121                                conf.int.style = "step",
122                                ylab = "Sobrevida estimada",
123                                xlab = "Tempo em meses",
124                                legend.title = "",
125                                legend.labs = c("53 anos ou mais",
126                                                "38 anos at menos 53 anos",
127                                                "25 anos at menos 38 anos",
128                                                "menos de 25 anos"))

```

```

129
130 gg_age$plot <- gg_age$plot +
131   ggplot2::scale_y_continuous(limits = c(0, 1),
132                               breaks = seq(0, 1, by = 0.1)) +
133   ggplot2::scale_x_continuous(limits = c(0, max(base$survivaltime)),
134                               breaks = seq(0, max(base$survivaltime), by = 10)) +
135   theme(legend.position = "bottom") +
136   scale_fill_discrete(labels=c('High Program', 'Low Program', 'c', 'd'))
137
138
139 # teste log-rank
140 test_age <- survdiff(Surv(time = survivaltime,
141                           event = dead) ~ aux_age,
142                      data = base)
143
144
145 # histologia -----
146 ajuste_hist <- survfit(Surv(time = survivaltime,
147                             event = dead) ~ hist,
148                        data = base)
149
150 # estimativas sobrevida por kaplan-meier
151 kp_hist <- surv_summary(ajuste_hist, data = base)
152
153 # gr fico sobrevida estimada
154 gg_hist <- survminer::ggsurvplot(ajuste_hist,
155                                   data = base,
156                                   pval = FALSE,
157                                   conf.int=TRUE,
158                                   conf.int.style = "step",
159                                   ylab = "Sobrevida estimada",
160                                   xlab = "Tempo em meses",
161                                   legend.title = "",
162                                   legend.labs = c("Esclerose Nodular",
163                                                  "Misto Celular",
164                                                  "Deple o de Linf citos"))
165
166 gg_hist$plot
167
168 gg_hist$plot <- gg_hist$plot +
169   scale_y_continuous(limits = c(0, 1),
170                       breaks = seq(0, 1, by = 0.1)) +
171   scale_x_continuous(limits = c(0, max(base$survivaltime)),
172                       breaks = seq(0, max(base$survivaltime), by = 10)) +
173   theme(legend.position = "bottom")
174
175 # teste log-rank
176 test_hist <- survdiff(Surv(time = survivaltime,
177                             event = dead) ~ hist,
178                       data = base)
179
180 # estagio da doen a -----
181 ajuste_stage <- survfit(Surv(time = survivaltime,
182                               event = dead) ~ stage,
183                          data = base)
184
185 # estimativas sobrevida por kaplan-meier
186 kp_stage <- surv_summary(ajuste_stage, data = base)
187
188 # gr fico sobrevida estimada
189 gg_stage <- survminer::ggsurvplot(ajuste_stage,
190                                   data = base,
191                                   pval = FALSE,
192                                   conf.int=TRUE,
193                                   conf.int.style = "ribbon",
194                                   ylab = "Sobrevida estimada",
195                                   xlab = "Tempo em meses",
196                                   legend.title = "",
197                                   legend.labs = c("Inicial",
198                                                  "Avan ado"))
199
200 gg_stage$plot <- gg_stage$plot +
201   scale_y_continuous(limits = c(0, 1),

```

```

202         breaks = seq(0, 1, by = 0.1)) +
203     scale_x_continuous(limits = c(0, max(base$survivaltime)),
204         breaks = seq(0, max(base$survivaltime), by = 10)) +
205     theme(legend.position = "bottom")
206
207 # teste log-rank
208 test_stage <- survdiff(Surv(time = survivaltime,
209         event = dead) ~ stage,
210     data = base)

```

6.2 Códigos utilizados no Cenário 2

```

1 # ANaLISE DE SOBREVIVeNCIA
2 # EXERCiCIO 4 DA LISTA 3
3
4 # bibliotecas -----
5 require(survival)
6 require(survminer)
7 require(summarytools)
8 require(dplyr)
9 require(flexsurv)
10
11 # base de dados -----
12 base <-
13     cbind(
14         c(0.19, 0.78, 0.96, 1.31, 2.78, 3.16, 4.67, 4.85,
15             6.50, 7.35, 8.27, 12.07, 32.52, 33.91, 36.71),
16         rep(1, 15))
17
18 colnames(base) <- c("temp_falha", "ind_falha")
19 base <- as_tibble(base)
20
21 # kaplan meier -----
22 KaplanMeir <-
23     survfit(
24         Surv(time = temp_falha,
25             event = ind_falha) ~ 1,
26         data = base
27     )
28
29 st_KaplanMeier <- KaplanMeir$surv
30
31 # exponential -----
32 modelExponential <-
33     flexsurvreg(
34         Surv(
35             time = temp_falha,
36             event = ind_falha
37         ) ~ 1,
38         data = base,
39         dist = "exponential"
40     )
41
42 st_Exponencial <- as.data.frame(summary(modelExponential))$est
43
44 # weibull -----
45 modelWeibull <-
46     flexsurvreg(
47         Surv(
48             time = temp_falha,
49             event = ind_falha
50         ) ~ 1,
51         data = base,
52         dist = "weibull"
53     )
54
55 st_Weibull <- as.data.frame(summary(modelWeibull))$est
56
57 # log normal -----
58 modelLogNorm <-
59     flexsurvreg(
60         Surv(
61             time = temp_falha,

```

```

62     event = ind_falha
63   ) ~ 1,
64   data = base,
65   dist = "lognorm"
66 )
67
68 st_LogNorm <- as.data.frame(summary(modelLogNorm))$est
69
70 # log logistic -----
71 modelLogLogistic <-
72   flexsurvreg(
73     Surv(
74       time = temp_falha,
75       event = ind_falha
76     ) ~ 1,
77     data = base,
78     dist = "llogis"
79   )
80
81 st_LogLogistic <- as.data.frame(summary(modelLogLogistic))$est
82
83 # gr ficos comparativos -----
84
85 # base com as estimativas de KP, EXP, WEIBULL, LOGNORM e LOGLOGISTICA
86 sts <- cbind(
87   base$temp_falha,
88   st_KaplanMeier,
89   st_Exponencial,
90   st_Weibull,
91   st_LogNorm,
92   st_LogLogistic
93 ) %>%
94 as_tibble()
95
96 # KP x EXP
97 ggExp <- sts %>%
98   ggplot(aes(x = st_KaplanMeier,
99             y = st_Exponencial)) +
100   geom_point() +
101   xlab("S(t): Kaplan-Meier") +
102   ylab("S(t): Exponencial") +
103   theme_classic() +
104   geom_abline(color = "red") +
105   scale_x_continuous(breaks = seq(0,1, 0.1)) +
106   scale_y_continuous(breaks = seq(0,1, 0.1))
107
108 # KP x WEIBULL
109 ggWeib <- sts %>%
110   ggplot(aes(x = st_KaplanMeier,
111             y = st_Weibull)) +
112   geom_point() +
113   xlab("S(t): Kaplan-Meier") +
114   ylab("S(t): Weibull") +
115   theme_classic() +
116   geom_abline(color = "red") +
117   scale_x_continuous(breaks = seq(0,1, 0.1)) +
118   scale_y_continuous(breaks = seq(0,1, 0.1))
119
120 # KP x LN
121 ggLN <- sts %>%
122   ggplot(aes(x = st_KaplanMeier,
123             y = st_LogNorm)) +
124   geom_point() +
125   xlab("S(t): Kaplan-Meier") +
126   ylab("S(t): Log-Normal") +
127   theme_classic() +
128   geom_abline(color = "red") +
129   scale_x_continuous(breaks = seq(0,1, 0.1)) +
130   scale_y_continuous(breaks = seq(0,1, 0.1))
131
132 # KP x LL
133 ggLL <- sts %>%
134   ggplot(aes(x = st_KaplanMeier,

```



```

135         y = st_LogLogistic)) +
136     geom_point() +
137     xlab("S(t): Kaplan-Meier") +
138     ylab("S(t): Log Log stica") +
139     theme_classic() +
140     geom_abline(color = "red") +
141     scale_x_continuous(breaks = seq(0,1, 0.1)) +
142     scale_y_continuous(breaks = seq(0,1, 0.1))
143
144 # erro quadr tico
145 eq <- sts %>%
146   mutate(eq_Exp2 = (st_KaplanMeier - st_Exponencial)^2,
147          eq_Wei2 = (st_KaplanMeier - st_Weibull )^2,
148          eq_LN2 = (st_KaplanMeier - st_LogNorm )^2,
149          eq_LL2 = (st_KaplanMeier - st_LogLogistic)^2,
150          ) %>%
151   select(eq_Exp2, eq_Wei2, eq_LN2, eq_LL2)
152
153 # erro quadr tico m dio
154 mqe <- apply(eq, 2, sum)/length(base$temp_falha)
155
156 # tabela par metros estimados
157 est <- modelLogNorm$res # escala original
158 est_log <-modelLogNorm$res.t # escala log
159
160 muln <- modelLogNorm$res[1,1]
161 sdln <- modelLogNorm$res[2,1]
162
163 # tempo mediano
164 t_0.5 = exp( (qnorm(0.5) * sdln) + muln)
165
166 # tempo medio
167 tm = exp( muln + ( (sdln^2) / 2 ) )
168
169 # tempo isolante 20% rupturados
170 z_0.2 <- qnorm(0.2)
171 t = exp(muln + (sdln * z_0.2) )

```